卷积神经网络

目前，我们处理任何结构的信息，都只会选择`将整个数据展开成一维向量`，这样就会忽略图像的空间结构信息。

> 为了改进上面的缺点，提出了`卷积神经网络`，是一个很强大的，为了处理图像数据提出的神经网络。

卷积神经网络的基本元素：卷积层本身、填充、步幅、在相邻区域汇聚信息的汇聚层、在每一层多个通道的使用。
最后会介绍一个完整的 可以运行的leNet模型。（是很早就成功应用的卷积神经网络）

1.从全连接层次到卷积层

1.1平移不变性和局部性

这是两个CNN里面很重要的想法。

平移不变性：不管检测对象出现在图像中的哪个位置，神经网络的前面几层应该对相同的图像区域具有相似的反应，即为“平移不变性”。
这一部分也可以总结为`不变性`，当我们要检测的物体出现的时候，只要检测到我们就认为它出现了，不去关注是否应该在图片的合理的位置，比如水里面、陆地上这种观点。

局部性：神经网络应该只探索`输入图像里面的局部区域`，而不要在意图像中相隔较远的区域的关系。

2.图像卷积

学习一下卷积层的实际应用。

2.1互相关运算过程：

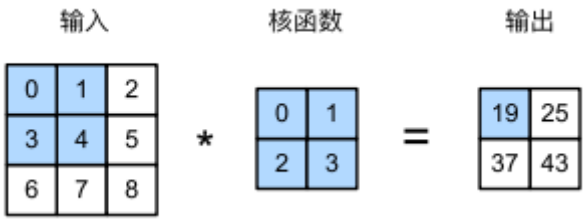

目前仅仅考虑二维的情况，暂且不讨论第三维度的情况。

卷积核上图的高度和宽度都是2，也就是$\begin{matrix}0 & 1\\ 2 & 3\end{matrix}$。

二维互相关运算过程：卷积窗口从输入的张量左上角开始，从左往右、从上往下进行滑动。
每一次滑动之后，**包含在该窗口中的部分张量与卷积核张量进行按元素相乘**，得到一个标量值，就是当前位置的输出。
上图的实际计算得到输出的过程为：

```
0 × 0 + 1 × 1 + 3 × 2 + 4 × 3 = 19,
1 × 0 + 2 × 1 + 4 × 2 + 5 × 3 = 25,
3 × 0 + 4 × 1 + 6 × 2 + 7 × 3 = 37,
4 × 0 + 5 × 1 + 7 × 2 + 8 × 3 = 43.
```

尺寸、大小的说明：输入大小为(n_h, n_w),卷积核大小为(k_h, k_w)。
得到的输出的大小为：$(n_h - k_h + 1, n_w - k_w + 1)$。

2.1.2手动互相关运算的代码实现：

```
import torch
from torch import nn

def corr2d(X, K):   #@save
      """计算二维互相关运算"""
      h, w = K.shape
      Y = torch.zeros((X.shape[0] - h + 1, X.shape[1] - w + 1))
      #这里直接指明Y的shape,防止越界访问元素
      for i in range(Y.shape[0]):
            for j in range(Y.shape[1]):
                  Y[i, j] = (X[i:i + h, j:j + w] * K).sum()
      return Y

#声明张量X和卷积核张量K，调用函数进行计算：
X = torch.tensor([[0.0, 1.0, 2.0], [3.0, 4.0, 5.0], [6.0, 7.0, 8.0]])
K = torch.tensor([[0.0, 1.0], [2.0, 3.0]])
print( corr2d(X, K))
```

结果为：$\begin{matrix} 19 & 25 \\ 37 & 43 \end{matrix}$

2.1.3卷积层的调库实现：

高度和宽度分别为 h 和 w 的卷积核可以被称为 h × w 卷积或 h × w 卷积核。我们也将带有 h × w 卷积核的卷积层称为 h × w 卷积层。

- **引入目标的边缘检测问题**：
  通过找到像素变化的位置，来检测图像中不同颜色的边缘。初始图像为：

```
X = torch.ones((6, 8))
X[:, 2:6] = 0
X
```

```
tensor([[1., 1., 0., 0., 0., 0., 1., 1.],
        [1., 1., 0., 0., 0., 0., 1., 1.],
        [1., 1., 0., 0., 0., 0., 1., 1.],
        [1., 1., 0., 0., 0., 0., 1., 1.],
        [1., 1., 0., 0., 0., 0., 1., 1.],
        [1., 1., 0., 0., 0., 0., 1., 1.]])
```

  中间四列为黑色(0)，其余像素都是白色(1)。

  理论情况下，我们需要一个卷积核为：

```
K = torch.tensor([[1.0, -1.0]])
```

  卷积核解释：shape = (1,2)。如果两个输入元素相同，结果为0。如果输入是[1,0]结果是1.(从白色到黑色的边界)输入是[0,1]，结果为-1。 (从黑色到白色的边界)。

上述问题的结果为：

```
tensor([[ 0.,  1.,  0.,  0.,  0., -1.,  0.],
        [ 0.,  1.,  0.,  0.,  0., -1.,  0.],
        [ 0.,  1.,  0.,  0.,  0., -1.,  0.],
        [ 0.,  1.,  0.,  0.,  0., -1.,  0.],
        [ 0.,  1.,  0.,  0.,  0., -1.,  0.],
        [ 0.,  1.,  0.,  0.,  0., -1.,  0.]])
```

因为没有进行填充，步幅为1，所以最后的**结果的宽度会减一。**

> 借助库来实现卷积层：
> 还是解决上面的问题，定义变量X是输入，Y是输出。
> 声明一个卷积层，通过迭代让卷积核自己学习参数。

- 二维卷积层的声明：
  此题需要：构造一个二维卷积层，它具有1个输出通道和形状为（1，2）的卷积核。

```
conv2d = nn.Conv2d(1,1, kernel_size=(1, 2), bias=False)
```

参数解释：

1. `nn.Conv2d(1, 1, kernel_size=(1, 2), bias=False)`：

- `1` **(输入通道数)**：卷积操作的输入特征图的通道数为 1。通常，对于单通道图像（如灰度图像），`in_channels` 为 1。
- `1` **(输出通道数)**：卷积操作将生成一个输出通道（即一个特征图）。所以这里输出的特征图是单通道的。
- `kernel_size=(1, 2)`：卷积核的大小为 1x2。这里表示卷积核的高度是 1，宽度是 2。也就是说，每次卷积操作会在输入特征图中选择一个 1 行 2 列的区域进行计算。卷积核的高度和宽度可以分别设置为单独的数值，因此 `(1, 2)` 表示垂直方向上只跨一行，水平方向上跨两列。
- `bias=False`：表示不使用偏置项。卷积层的输出通常是卷积核的加权和加上偏置，但这里显式设置了 `bias=False`，意味着卷积层将不使用偏置。

对于Conv2d官方所有参数解释：

```
Args:
    in_channels (int): Number of channels in the input image
    out_channels (int): Number of channels produced by the convolution
    kernel_size (int or tuple): Size of the convolving kernel
    stride (int or tuple, optional): Stride of the convolution. Default: 1
    padding (int, tuple or str, optional): Padding added to all four sides of
        the input. Default: 0
    padding_mode (string, optional): ``'zeros'``, ``'reflect'``,
        ``'replicate'`` or ``'circular'``. Default: ``'zeros'``
    dilation (int or tuple, optional): Spacing between kernel elements. Default: 1
    groups (int, optional): Number of blocked connections from input
        channels to output channels. Default: 1
    bias (bool, optional): If ``True``, adds a learnable bias to the
        output. Default: ``True``
""".format(**reproducibility_notes, **convolution_notes) + r"""
```

文件位置：

`"D:\ProgramData\anaconda3\envs\d2l\Lib\site-packages\torch\nn\modules\conv.py"`

- 完整代码和解释：

```
#构造输入和标准输出
X = torch.ones((6, 8))
X[:, 2:6] = 0

Y = torch.zeros((6,7))
Y[:,1] = 1
Y[:,-2] = -1

```

```
9
10  # 构造一个二维卷积层，它具有1个输出通道和形状为（1，2）的卷积核
11  conv2d = nn.Conv2d(1,1, kernel_size=(1, 2), bias=False)
12  # 这个二维卷积层使用四维输入和输出格式（批量大小、通道、高度、宽度），
13  # 其中批量大小和通道数都为1
14  X = X.reshape((1, 1, 6, 8))
15  print(X)
16  Y = Y.reshape((1, 1, 6, 7))
17  print(Y)
18  lr = 3e-2  # 学习率
19
20  for i in range(10):
21        Y_hat = conv2d(X)
22        # print(Y_hat)
23        l = (Y_hat - Y) ** 2
24        conv2d.zero_grad()
25        l.sum().backward()
26        # 迭代卷积核
27        conv2d.weight.data[:] -= lr * conv2d.weight.grad
28        if (i + 1) % 2 == 0:
29              print(f'epoch {i+1}, loss {l.sum():.3f}')
```

- **输入和输出的格式要求**：
  输入和输出的格式都要求：**四维输入和输出格式（批量大小、通道、高度、宽度）**。
  所以，我们首先要将X,Y进行reshape。
  - 对于一个二维张量X。
    如果X.shape = (H,W)。
    通过执行： `X = X.reshape((1, 1) + X.shape)` 就会对张量 `X` 进行形状调整。
  - `(1, 1)`：这个元组表示要在形状的前两维前加上两个维度，值都为1。这通常是为了将 `X` 转换为一个有 4 个维度的张量，形状的前两维表示通道数和批次大小。

    `(1, 1) + X.shape`：通过将 `(1, 1)` 和 `X.shape` 拼接起来，得到一个新的元组。举例来说，如果 `X.shape` 是 `(H, W)`，则 `X.reshape((1, 1) + X.shape)` 就是将 `X` 的形状转换为 `(1, 1, H, W)`。如果 `X.shape` 本来就是 `(C, H, W)`，则新的形状会变成 `(1, 1, C, H, W)`。

    `X.reshape(...)`：这部分是将 `X` 重新调整为新的形状，保持数据的内容不变，只是调整了它的维度。
- 整个迭代的过程，以及参数更新的操作，在上述代码。

2.2互相关和卷积

互相关和卷积计算并不是一回事，两者有细微的差别。

`more formally:` 只需水平和垂直翻转二维卷积核张量，然后对输入张量执行互相关运算。
上述过程就是卷积计算。

这一部分的具体过程可以看 **链接1**， **链接2**。

值得注意的是，由于卷积核是从数据中学习到的，因此无论这些层执行严格的卷积运算还是互相关运算，卷积层的输出都不会受到影响。为了说明这一点，假设卷积层执行互相关运算并学习 图6.2.1中的卷积核，该卷积核在这里由矩阵$\mathbf{K}$表示。假设其他条件不变，当这个层执行严格的卷积时，学习的卷积核$\mathbf{K}'$在水平和垂直翻转之后将与$\mathbf{K}$相同。也就是说，当卷积层对 图6.2.1中的输入和$\mathbf{K}'$执行严格卷积运算时，将得到与互相关运算 图6.2.1中相同的输出。

为了与深度学习文献中的标准术语保持一致，我们将继续把“互相关运算”称为卷积运算，尽管严格地说，它们略有不同。此外，对于卷积核张量上的权重，我们称其为元素。

2.3感受野

定义：对于CNN每一层输出的 特征图 上面的每一个元素，它的感受野就是**相对于原图，这个点能够看到的输入图像的区域。**

举例说明：

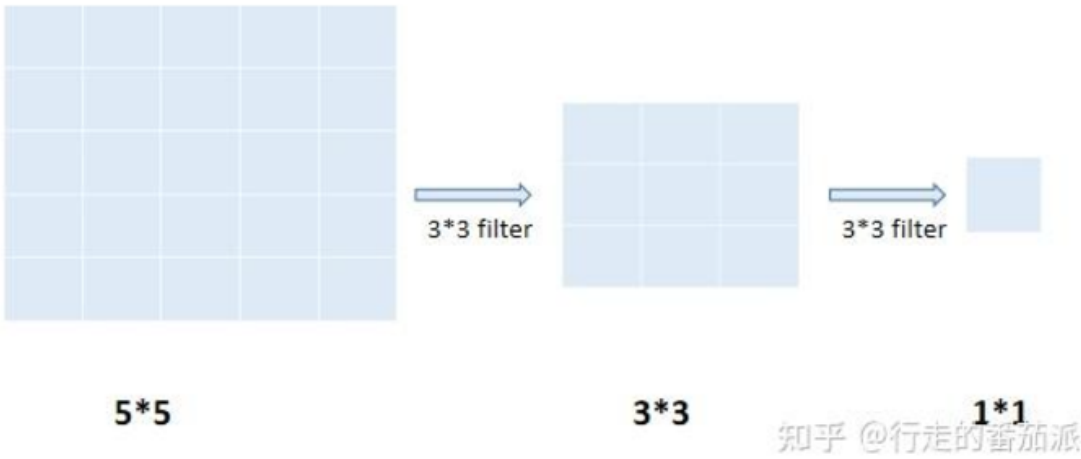

输入的图像shape为$5*5$，经过一次卷积之后，得到$3*3$的特征图，此时每一个特征图里面的元素对应的 感受野的尺寸为3*3 。
再经过一次卷积之后，最后得到一个元素，此时，这个元素的感受野的尺寸是 5*5 。也就是整个输入的图像。

```
(d2l) D:\Users\gxy\OneDrive\directory\graduate_study\DEEP_learning\Code_of_book\pytorch\chapter_convolutional-neural-networks>python
Python 3.9.20 (main, Oct  3 2024, 07:38:01) [MSC v.1929 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>>
```

3.填充和步幅

卷积的输出形状取决于输入形状和卷积核的形状。

公式为：

尺寸、大小的说明： 输入大小为(n_h, n_w),卷积核大小为(k_b, k_w)。
得到的输出的大小为：$(n_h - k_h + 1, n_w - k_w + 1)$。

3.1填充(包括填充的调库实现)

根据上面公式，当我们使用多层卷积时，会丢失边缘像素。
虽然当我们使用一个很小的卷积核时，并不会减少很多的像素，但是如果我们使用多层次的，每一层都会减少。就会导致 累积丢失很多像素 。

为了解决这个问题，可以使用**填充**：在输入图像的边界填充元素。（填充的元素通常都是0）。

- 填充举例：

- 没有填充之前：

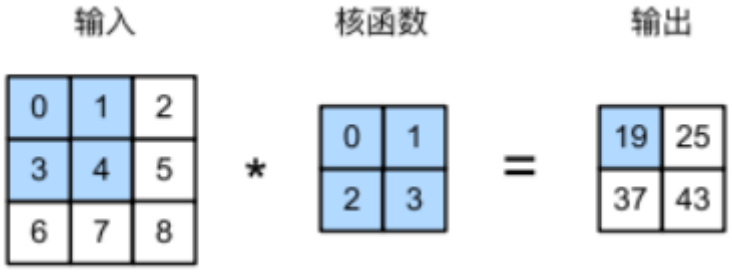

- 填充之后：将3 × 3输入填充到5 × 5，那么它的输出就增加为4 × 4。

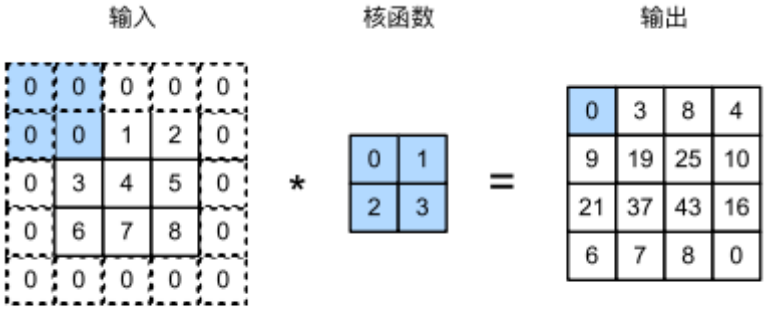

图6.3.1: 带填充的二维互相关。

- 如果我们一共添加p_h行，p_w列。一般添加的时候一半在一边、另外一半在另一边。
  此时最后的尺寸为：
  $n_h - k_h - p_h + 1, n_w - k_w + p_w + 1$。
  在许多情况下，我们需要设置$p_h = k_h - 1$和$p_w = k_w - 1$，使输入和输出具有相同的高度和宽度。这样可以在构建网络时更容易地预测每个图层的输出形状。假设k_h是奇数，我们将在高度的两侧填充$p_h/2$行。如果k_h是偶数，则一种可能性是在输入顶部填充$\lceil p_h/2 \rceil$行，在底部填充$\lfloor p_h/2 \rfloor$行。同理，我们填充宽度的两侧。

  卷积神经网络中卷积核的高度和宽度通常为奇数，例如1、3、5或7。选择奇数的好处是，保持空间维度的同时，我们可以在顶部和底部填充相同数量的行，在左侧和右侧填充相同数量的列。

- **代码实现：**
  创建一个高度和宽度为3的二维卷积层。

  给定高度和宽度为8的输入，在输入图像的所有侧边都填充一个像素，最后输出的高度和宽度还是8。

  - 调库使用卷积层：

```
conv2d = nn.Conv2d(1, 1, kernel_size=3, padding=1)
```

    参数分别表示：输入通道数为1，输出通道数为1。卷积核的shape是3×3.
    padding = 1表示每一个侧边都填充一个像素。

  - 创建输入变量：`X = torch.rand(size=(8, 8))`

  - 进行卷积操作：

```
#输入图像，调整为四维的输入格式。
X = X.reshape((1, 1) + X.shape)
#卷积操作得到Y
Y = conv2d(X)
#得到的Y此时也是四维格式，我们只保留最后两个维度的信息
Y.reshape(Y.shape[2:])
```

    需要注意的是： nn.conv2d函数，标准输入输出格式都是四个维度。
    （input_channel,output_channel,h,w）。

3.2步幅(包括步幅的调库实现)

之前所有的例子里面，我们的卷积窗口口从输入张量的左上角开始，向下、向右滑动。
每一次滑动平移的位置都是1，**每一次滑动元素的数量是步幅**，现在我们允许使用较大的步幅。

比如当我们将上述问题修改为`垂直步幅为3，水平步幅为2`：(**如果想要复现这个结果，需要将bias设置为False**)。

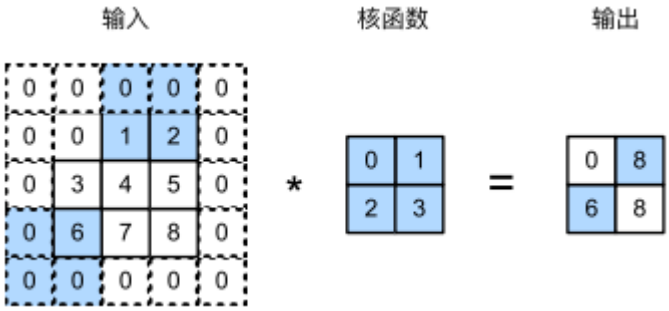

一旦不能满足下一次滑动之后卷积窗口都有元素，就会停止滑动。
此时最后输出的形状为：
$(n_h - k_h + p_h + s_h)/s_h, (n_w - k_w + p_w + s_w)/s_w$。注意都是向下取整。

如果我们设置了$p_h = k_h - 1$、$p_w = k_w - 1$，则输出形状将简化为$(n_h/s_h, n_w/s_w)$。

- 上述图示步幅的代码实现：
  原先：

```
conv2d = nn.Conv2d(1, 1, kernel_size=3, padding=1)
```

  现在：

```
conv2d = nn.Conv2d(1, 1, kernel_size=3, padding=1 , stride = (3,2),bias = False)
```

  步幅的设置，第一个维度是垂直方向，第二个是水平方向。

- 指定核函数的值：

```
kernel = torch.tensor([[[[0, 1],[2, 3]]]], dtype=torch.float)  # 1 个输入通道，1 个输出通道，2x2 核
 with torch.no_grad():
      conv2d.weight = nn.Parameter(kernel)
```

- 完整代码：

```
import torch
import torch.nn as nn

# 定义输入张量
A = torch.tensor([[0, 1, 2],
                  [3, 4, 5],
                  [6, 7, 8]], dtype=torch.float)

# 定义卷积核（核函数）
kernel = torch.tensor([[[[0, 1],
                         [2, 3]]]], dtype=torch.float)  # 1 个输入通道，1 个输出通道，2x2 核

# 创建卷积层
conv2d = nn.Conv2d(in_channels=1, out_channels=1, kernel_size=2, padding=1, bias=False,stride = (3,2))

```

```
# 手动设置卷积核权重
with torch.no_grad():
      conv2d.weight = nn.Parameter(kernel)

# 将输入张量 A 调整为符合 Conv2d 的输入形状 (batch_size, channels, height, width)
A = A.reshape((1,1) + A.shape)

# 执行卷积操作
B = conv2d(A)

# 打印结果
print("输入：")
print(A)
print("卷积核：")
print(kernel)
print("输出：")
print(B)
```